

Московский физико-технический институт

Домашнее задание

Построение и анализ филогенетических деревьев

Выполнила студентка группы Б06-305

Сухорукова Мария

г.Долгопрудный, 2026

1 Подготовка данных

Взяли ген SCN1A, кодирующий альфа-субъединицу натриевого канала NaV1.1. Нашли ортологов, переименовали под формат.

```
import re

def rename_fasta_headers(input_file, output_file):
    with open(input_file, 'r') as f_in, open(output_file, 'w') as f_out:
        for line in f_in:
            if line.startswith('>'):
                # Извлекаем Accession (например, NP_061820.1)
                accession_match = re.search(r'>(\S+)', line)
                organism_match = re.search(r'\[organism=(\[w\s]+\)\]', line)

                if accession_match and organism_match:
                    acc = accession_match.group(1)
                    # Заменяем пробелы в названии организма на подчеркивания
                    org = organism_match.group(1).replace(' ', '_')
                    new_header = f">{org}_{acc}\n"
                    f_out.write(new_header)
                else:
                    # Если формат вдруг другой, оставляем как есть
                    f_out.write(line)
            else:
                # Записываем саму последовательность без изменений
                f_out.write(line)

# Запуск функции
rename_fasta_headers('protein.faa', 'renamed_orthologs.fasta')
print("Переименование завершено!")
```

2 Множественное выравнивание

3 Построение филогенетических деревьев

4 Анализ и сравнение результатов

4.1 Как соотносятся между собой деревья, полученные разными методами?

Деревья, полученные методами Maximum Likelihood и Neighbor-Joining, демонстрируют высокую степень топологического сходства. Они оба учитывают разные скорости эволюции ветвей, поэтому группировка основных таксонов (парнокопытные, китообразные, рукокрылые) в них практически идентична.

Дерево UPGMA визуально отличается, метод предполагает одинаковую скорость накопления мутаций во всех линиях. В результате длины ветвей от узла до всех дочерних листьев

Table. Maximum Likelihood analysis of substitution models									
Model	Parameters	BIC	AICc	lnL	(+I)	(+G)	f(A)	f(R)	f(N)
JTT+G+I	217	25437.023	23209.902	-11387.728	0.69	0.75	0.077	0.051	0.043
LG+G+I	217	25480.952	23253.831	-11409.692	0.69	0.73	0.079	0.056	0.042
WAG+G+I	217	25538.405	23311.283	-11438.418	0.69	0.75	0.087	0.044	0.039
JTT+G+I+F	236	25557.986	23135.905	-11331.689	0.66	0.64	0.056	0.047	0.053
JTT+I	216	25584.742	23367.882	-11467.720	0.76	n/a	0.077	0.051	0.043
cpREV+G+I	217	25590.534	23363.413	-11464.483	0.68	0.68	0.076	0.062	0.041
LG+I	216	25634.596	23417.736	-11492.647	0.76	n/a	0.079	0.056	0.042
WAG+G+I+F	236	25635.618	23213.538	-11370.505	0.65	0.62	0.056	0.047	0.053
LG+G+I+F	236	25667.238	23245.157	-11386.315	0.66	0.62	0.056	0.047	0.053
WAG+I	216	25691.030	23474.170	-11520.864	0.76	n/a	0.087	0.044	0.039
JTT+I+F	235	25713.143	23301.323	-11415.400	0.76	n/a	0.056	0.047	0.053
Dayhoff+G+I+F	236	25722.782	23300.702	-11414.087	0.65	0.62	0.056	0.047	0.053

Рис. 3: Нашли лучшую модель JTT+G+I

4.2 Можно ли выделить на деревьях клады, соответствующие известным таксономическим группам?

Нвсех трех деревьях четко выделяются монофилетические клады, подтвержденные классической систематикой:

- Cetartiodactyla (Китопарнокопытные): Виды *Dama dama* (лань), *Muntiacus reevesi* (мунт-жак), *Ovis canadensis* (баран) и *Globicephala melas* (гринда) всегда образуют единый крупный кластер.
- Chiroptera (Рукокрылые): Группа, включающая *Plecotus auritus* (ушан), *Myotis nattereri* (ночница) и *Rhinolophus* (подковонос), стабильно обособлена.
- Rodentia (Грызуны): Виды *Dipodomys merriami* и *Psammomys obesus* объединяются в общую ветвь.

Это свидетельствует о том, что белок NaV1.1 сохранил четкий филогенетический сигнал, отражающий реальную эволюцию млекопитающих.

4.3 Насколько надежны полученные деревья?

Анализ значений бутстрепа (числа на узлах) показывает разную степень надежности для разных уровней родства: Высокая надежность (90–100%): Наблюдается на терминальных узлах, объединяющих близкородственные виды одного семейства или рода (например, внутри рода *Microsebus* или *Dama* поддержка почти всегда равна 100). Средняя и низкая надежность (ниже 70%): Встречается в глубоких узлах, разделяющих крупные отряды. Низкие значения (например, 14–23% в некоторых узлах ML-дерева) указывают на то, что для разрешения столь древних эволюционных событий данных одного белка недостаточно, либо разделение этих групп происходило очень быстро.

4.4 Какой из методов, на ваш взгляд, лучше всего отражает эволюционную историю выбранного гена?

Наиболее адекватным методом для данного набора данных является Maximum Likelihood. ML использует заранее вычисленную лучшую модель замещений (JTT+G+I), которая учитывает неравномерность скоростей эволюции в разных сайтах белка. В отличие от UPGMA, ML не накладывает ограничение «равных скоростей», что критично для белков млекопитающих, которые могли эволюционировать с разной интенсивностью в разных экологических




Рис. 4: ML дерево




Рис. 5: NJ дерево




Рис. 6: UPGMA дерево

нишах. ML оценивает вероятность всей топологии дерева целиком, что делает его «золотым стандартом» современной молекулярной филогенетики.